

APIs Modulares de Missao Critica (FastAPI) com Paginacao, Cache e Rate Limiting

Arquitetura Full Stack

Autor
Marcos L. R. V. (Coordenador de Engenharia)

Unidade
V4 Company / Squad de Engenharia de IA

Data
2026-08-27

Status
Entregue (desenvolvido)

API modular FastAPI para dados de missao critica, com paginacao cursor-based, cache Redis com invalidacao e rate limiting por chave. Entrego o padrao e uma implementacao real.

Foco em corretude sob carga: uma API de leads nao pode vaziar memoria nem derrubar o banco em pico.

- Endpoints internos servem 3-5 sistemas.
- Listas de 5k-80k sem paginacao estouravam memoria.
- Sem rate limit: 2k req/min derrubava o Postgres.

Sintoma	Hoje	Alvo
Paginacao	offset	cursor-based
Cache	nenhum	Redis + invalidacao
Rate limit	ausente	por api_key
Erro 5xx	stack cru	envelope

- Offset em tabelas grandes = full scan.
- Conexoes nao pooladas -> esgotamento.

- Sem distincão 4xx vs 5xx.

ADR-032 — API Modular

Opção	Pro	Contra	Decisão
FastAPI + Redis + slowapi	async, maduro	mais deps	ESCOLHIDA
Flask manual	simples	menos perf	rejeitada

Cursor-based para estabilidade; cache por chave com invalidação no write.

- API-STANDARD.md.
- main_api.py.
- requirements.txt.

1. Carga com k6: 200 req/s por 5 min.
2. Rate limit: estourar quota -> 429.
3. Cache: 2o hit vem do Redis.

SLO	Alvo
p95 (lista)	< 200 ms cache hit
Rate limit	100/min/key
Disponibilidade	>= 99.5%

Risco	Mitigação
Cache stale	TTL + invalidar no write
Redis down	fallback DB

- Gateway com OAuth2.
- Tracing OTel.