

Arquitetura Serverless para Processamento Assíncrono (event-driven)

Arquitetura Full Stack

Autor
Marcos L. R. V. (Coordenador de Engenharia)

Unidade	Data
V4 Company / Squad de Engenharia de IA	2026-08-27

Status
Entregue (desenvolvido)

Desenho serverless event-driven para processar uploads e webhooks sem servidor sempre ligado: fila + funcao + armazenamento, com backpressure e retries. Entrego o padrao e um handler real.

Valor: custo por uso + escala automatica sob rajada.

- Clientes enviam planilhas de 1k-50k linhas.
- Worker always-on: 90% ocioso.
- Pico de 200 uploads derrubava o worker.

Hoje	Alvo
worker ocioso	scale to zero
sem fila	queue + retry
sem isolamento	1 falha nao derruba

- Processamento sincrono no request = timeout.
- Sem idempotencia: reprocessar duplicava leads.
- Sem limite de concorrencia.

ADR-033 — Serverless event-driven

Opcao	Pro	Contra	Decisao
Fila + funcao + store	scale to zero	cold start	ESCOLHIDA
Lambda direto no upload	simples	sem backpressure	rejeitada

Upload grava objeto e publica evento; consumo com concorrencia limitada e dedup.

- SERVERLESS-STANDARD.md.
- process_upload.py.
- terraform_serverless.tf.

1. Enviar 200 planilhas; medir paralelismo e custo.
2. Forcar falha parcial; confirmar retry + sem duplicata.
3. 1 arquivo ruim nao afeta os outros.

SLO	Alvo
Custo/1k planilhas	< R\$ 0,20
P95	< 60 s
Duplicatas	0

Risco	Mitigacao
Cold start	provisioned concurrency
Fila sem limite	DLQ

- Observabilidade por trace_id.
- Workers de agentes no mesmo molde.