

Fundamentos de IA Generativa (NVIDIA DLI) aplicados a RAG

Engenharia de IA

Autor

Marcos L. R. V. (Coordenador de Engenharia)

Unidade

V4 Company / Squad de Engenharia de IA

Data

2026-08-27

Status

Entregue (desenvolvido)

Conclusao do curso NVIDIA DLI 'Building RAG Agents with LLMs' com transposicao pratica. Entrego notas e um notebook funcional de RAG end-to-end.

A base sustenta as proximas atividades (RAG hibrido, multi-agente, custos).

- Time comenta 'RAG' mas sem padrao de chunking.
- Similaridade pura trazia contexto irrelevante.
- Sem metrica de qualidade.
- Chunk grande -> ruido; pequeno -> perde contexto.
- Embedding sem normalizacao.
- Sem rerank -> top-k ruido.

ADR-041 — Baseline RAG

Opcao	Pro	Contra	Decisao
Chunk 512 + overlap 64 + rerank	coesos	mais tokens	ESCOLHIDA

Normalizar embeddings; top-k=20 + rerank para top-5.

- DLI-NOTES.md.
- rag_baseline.py.

- CONCLUSAO.md.

1. Rodar rag_baseline.py.
2. Medir faithfulness em 10 perguntas.
3. Comparar com similaridade pura.

SLO	Alvo
Faithfulness	>= 0.8
Chunk	512/64

Risco	Mitigacao
Contexto irrelevante	rerank
Hallucination	cite trecho

- RAG hibrido (04-A2).
- Avaliacao RAGAS.