

Peretto

marcos
Luciano

PDI — ATIVIDADE 01 · REGISTRO DE ENTREGA

Fundamentos de IA Generativa (NVIDIA DLI) aplicados a RAG

Autor: PDI Marcos Luciano - marcosluciano.rodrigues@v4company.com

Unidade: FV Marketing / V4 Company — Automação & Infraestrutura

Módulo: 04 · Engenharia de IA, RAG e Vetores

Data: Agosto 2026

Status: **NÃO PUBLICADO** · Desenvolvido / Homologação pendente

Versão: 1.0

tokens / embeddings / eval

1. Contexto

IA generativa parece mágica, mas por baixo é matemática de texto. Antes de escrever qualquer linha de código, um júnior precisa entender três ideias: **tokens** (como o modelo "enxerga" texto), **embeddings** (como o texto vira número) e **similaridade** (como comparamos significados). Sem isso, você não consegue nem avaliar se a resposta está certa.


ANALOGIA DA BIBLIOTECA

Pense no texto como um livro. O **token** é a letra/sílaba que o tradutor lê de cada vez. O **embedding** é o 'cartão de endereço' numérico desse trecho: frases parecidas caem em pontos próximos de um mapa. A **similaridade** é a régua que mede a

distância entre dois cartões. Guardrails são o bibliotecário que impede você levar livro proibido pra casa.

2. Diagnóstico

Sem entender embeddings, a equipe mandava o texto inteiro pro LLM e media acerto "no olhometro". Resultado: respostas fora do domínio passavam batidas e ninguém sabia onde o modelo errava. O custo oculto é a **falta de avaliação reproduzível**.



Raiz do problema: não existia um score objetivo (similaridade de embeddings + checklist de guardrails). O que não se mede, não se corrige.


3. Solução

Criar um **módulo de fundações**: tokenizador para contagem de custo, gerador de embeddings (modelo `text-embedding-3-small`) e um avaliador que compara a resposta gerada contra um golden set usando similaridade de cosseno + checagens de guardrail (tóxico, fora-de-domínio, vazamento de PII).

4. Como funciona (pipeline)

Pipeline de fundações e avaliação

FLUXO EM EXECUÇÃO



5. Antes vs Depois


CENÁRIO	ANTES (SEM BASE)	DEPOIS (FUNDAÇÕES)
Avaliação	Manual, no olhometro	Score automatizado por cosseno

Alucinação	Passava despercebida	Bloqueada por guardrail
Custo	Surpresa na fatura	Estimado antes da chamada
Reprodutibilidade	Inexistente	Golden set no CI

6. Entregas

- **Notebook** 01-tokens-embeddings.ipynb: explicação visual de tokenização e vetorização.
- **Script** embed.py: gera e salva embeddings com similaridade de cosseno.
- **Golden set** eval_set.json: 50 pares pergunta/resposta de referência.
- **Doc** guardrails.md: catálogo de checagens e limiares.

7. Métricas



Meta: score médio ≥ 0.90 no golden set com 100% das respostas passando pelos guardrails antes de produção.

8. Status final

NÃO PUBLICADO — Desenvolvido e em homologação. Aguarda revisão antes de produção.