

RAG Hibrido (BM25 + Vetorial) e GraphRAG para Relacoes

Engenharia de IA

Autor

Marcos L. R. V. (Coordenador de Engenharia)

Unidade

V4 Company / Squad de Engenharia de IA

Data

2026-08-27

Status

Entregue (desenvolvido)

Upgrade do RAG baseline para hibrido (BM25 + vetorial com RRF) e GraphRAG para relacoes. Entrego o padrao e implementacao.

Similaridade falha em 'qual contrato do cliente X' — Grafos cobrem isso.

- Relacionamento ('cliente->contrato->fatura') ruim.
- Termos exatos (CNPJ) nao recuperados por embeddings.
- BM25 sozinho perde sinonimos.

Caso	Vetorial	BM25	Hibrido
ID exato	ruim	otimo	otimo
sinonimo	otimo	ruim	otimo
relacao	ruim	ruim	grafo

ADR-042 — Recuperacao Hibrida + Grafo

Opcao	Pro	Contra	Decisao
BM25 + vetorial + GraphRAG	cobra todos	complexo	ESCOLHIDA

RRF funde ranks; GraphRAG via traversal.

- HYBRID-RAG.md.
- hybrid_rag.py.
- graph_schema.cypher.

1. Avaliar em 30 perguntas (10 exatas, 10 sinonimos, 10 relacao).
2. Comparar hit@5.
3. Confirmar GraphRAG resolve relacoes.

SLO	Alvo
hit@5 (relacao)	>= 0.9
hit@5 (exato)	>= 0.95

Risco	Mitigacao
Grafo desatualizado	rebuild incremental
RRF ruim	tunar

- RAGAS.
- Cache de subgrafos.