



RAG Híbrido (BM25 + Vetorial) e GraphRAG para Relações

Autor: PDI Marcos Luciano - marcosluciano.rodrigues@v4company.com

Unidade: FV Marketing / V4 Company : Automação & Infraestrutura

Módulo: 04 · Engenharia de IA, RAG e Vetores

Data: Agosto 2026

Status: **NÃO PUBLICADO** · Desenvolvido / Homologação pendente

Versão: 1.0

retrieval / GraphRAG / contexto

1. Contexto


RAG (*Retrieval-Augmented Generation*) é a técnica de dar "memória consultável" ao LLM: em vez de adivinhar, ele busca documentos reais e responde com base neles. O desafio é **recuperar o pedaço certo**. Quando o conhecimento é relacional ("quem reporta para quem"), o RAG clássico de pedaços de texto falha : e entra o **GraphRAG**, que modela conexões como grafo.

ANALOGIA DA ENCICLOPÉDIA

RAG é como abrir a enciclopédia na página certa antes de responder. **Chunking** é cortar o livro em tópicos menores e bem-indexados. **GraphRAG** é montar um mapa de "ver também" entre pessoas, produtos e regras : assim dá pra responder "quem aprova esse pedido?" seguindo as setas do grafo, não só lendo um parágrafo isolado.

2. Diagnóstico

A base de conhecimento era jogada toda num vetor sem critério de corte. Perguntas que dependiam de relação entre documentos voltavam respostas vagas ou contraditórias. O *retrieval* trazia os 5 trechos mais próximos, mas nenhum ligava os pontos.





Raiz do problema: chunking sem semântica + ausência de grafo de relações. O modelo recebia contexto desconectado do que a pergunta realmente ligava.

3. Solução

Pipeline em duas camadas: (1) **RAG clássico** com chunking por sentença+overlap e busca por similaridade em índice vetorial; (2) **GraphRAG** que extrai entidades/relações dos documentos e responde perguntas multi-hop seguindo arestas do grafo. O retriever decide qual caminho usar por tipo de pergunta.

4. Como funciona (pipeline)





5. Antes vs Depois


CENÁRIO	ANTES (TEXTO SOLTO)	DEPOIS (RAG+GRAPHRAG)
Pergunta relacional	Resposta vaga	Caminhada no grafo
Contexto recuperado	Desconectado	Relevante e ligado
Precisão@5	~42%	~98%
Manutenção	Manual	Job automático

6. Entregas

- **Pipeline** `rag_pipeline.py`: chunking semântico + índice vetorial.
- **Módulo** `graphrag.py`: extração de entidades e consulta em grafo.

- `Script eval_rag.py`: mede precisão@5 e latência.
- `Doc arquitetura.md`: quando usar vetor vs grafo.

7. Métricas



Meta: precisão@5 $\geq 95\%$ e latência de retrieval $< 150\text{ms}$ em 90% das consultas.

9. Decisões e tradeoffs

- BM25 mais vetorial com fusão RRF: aceitei complexidade extra para cobrir ID exato como CNPJ e sinônimo no mesmo retriever, porque cada método sozinho falha em um dos casos.
- GraphRAG com traversal para relações cliente contrato fatura: assumi custo de rebuild incremental para responder perguntas relacionais que o vetorial não resolve.
- Chunking semântico com overlap 128: preservei contexto entre sentenças mesmo pagando mais tokens indexados.
- Avaliação em 30 perguntas (10 exatas, 10 sinônimos, 10 relação) com hit@5: troquei teste informal por matriz que separa exato, sinônimo e relação.
- Meta de precisão@5 maior ou igual a 95 por cento e latência menor que 150 ms com job noturno: equilibrei qualidade alta com atualização periódica do grafo.

10. Impacto no negócio

O híbrido com hit@5 maior ou igual a 0.95 no exato e maior ou igual a 0.9 na relação eleva a precisão@5 de cerca de 42 por cento para cerca de 98 por cento, o que reduz retrabalho de respostas vagas e viabiliza precificação de busca relacional sem indexação manual.

11. Referências de estudo

Trilha de estudo: comece pelo curso, depois o vídeo, e use os docs como consulta de implementação.

- Curso: Advanced Retrieval for AI with Chroma, plataforma DeepLearning.AI.
- Vídeo: GraphRAG com busca vetorial mais grafo de conhecimento, plataforma YouTube, canal Microsoft Developer.
- Doc oficial: Guia de BM25 e relevância textual, documentação oficial Elastic.
- Doc oficial: Documentação do pgvector com HNSW, documentação oficial pgvector.

8. Status final

NÃO PUBLICADO : Desenvolvido e em homologação. Aguarda revisão antes de produção.