

Monitoramento de Custos e Consumo de Tokens de LLMs de Fronteira

Engenharia de IA

Autor	Unidade	Data	Status
Marcos Perettoco	V4 Company / FV Marketing	25/08/2026	Entregue (desenvolvido)

1. Contexto e Problema

Sem visibilidade de custo, o uso de LLMs de fronteira (OpenAI, Gemini) saía do controle em picos.

2. Diagnóstico

- Sem log de tokens por agente/modelo
- Sem tabela de preço atualizada
- Sem alerta de orçamento

3. Arquitetura da Solução

- Captura de prompt/completion tokens por Run
- Tabela de preço por 1k tokens (atualização mensal)
- Alertas: 80% warn, 100% block por agente
- Otimização: cache de prompt e modelo menor para tarefas simples

4. Entregas

- COST-MONITORING.md (padrão)
- usage_schema.sql (schema)
- track_cost.py (cálculo de custo)

5. Métricas de Sucesso

Métrica	Antes	Depois
Visibilidade de custo	0%	Por agente/modelo/dia
Alerta de orçamento	Não	Sim

6. Próximos Passos

- Instrumentar os agentes em produção
- Dashboard de custo no Command Center

Relatório gerado em 25/08/2026 · PDI Marcos Perettoco · V4 Company