

# Engenharia de Custos de LLM (custo por tarefa, cache, roteamento)

Engenharia de IA

Autor  
Marcos L. R. V. (Coordenador de Engenharia)

UnidadeData  
V4 Company / Squad de Engenharia de IA2026-08-27

Status  
Entregue (desenvolvido)

Framework de custo de LLM: custo por tarefa, cache de prompt, roteamento por complexidade e budget. Entrego o padrao e um calculador.

Sem contabilidade de tokens, nao se precifica o agente.

- Modelo 'maxi' para tudo (10x custo).
- Sem cache -> mesma pergunta paga 2x.
- Impossivel precificar ao cliente.

| Hoje            | Alvo         |
|-----------------|--------------|
| modelo unico    | roteamento   |
| sem cache       | cache        |
| custo invisivel | custo/tarefa |

## ADR-044 — Estrategia de Custo

| Opcao                       | Pro        | Contra     | Decisao   |
|-----------------------------|------------|------------|-----------|
| Roteamento + cache + budget | previsivel | governanca | ESCOLHIDA |

Trivial -> leve; complexo -> forte; repetido -> cache.

- LLM-COST.md.
- cost\_calc.py.
- BUDGET.md.

1. Medir custo/tarefa com e sem roteamento.
2. Habilitar cache; medir hit rate.
3. Budget por cliente + alerta 80%.

| SLO          | Alvo                         |
|--------------|------------------------------|
| Custo/tarefa | $\leq \text{baseline} * 0.4$ |
| Cache hit    | $\geq 30\%$                  |
| Budget       | alerta 80%                   |

| Risco         | Mitigacao         |
|---------------|-------------------|
| Qualidade cai | eval + roteamento |
| Cache PII     | nao cachear       |

- Precificar por tarefa.
- Dashboard de custo.

Dossie gerado em 2026-08-27 · PDI Marcos L. R. V. (Coordenador de Engenharia)