



PDI: ATIVIDADE 04 · REGISTRO DE ENTREGA

Engenharia de Custos de LLM (custo por tarefa, cache, roteamento)

Autor: PDI Marcos Luciano - marcosluciano.rodrigues@v4company.com

Unidade: FV Marketing / V4 Company: Automação & Infraestrutura

Módulo: 04 · Engenharia de IA, RAG e Vetores

Data: Agosto 2026

Status: **NÃO PUBLICADO** · Desenvolvido / Homologação pendente

Versão: 1.0

token / cache / finanças

1. Contexto



LLM cobra por **token** (entrada + saída). Em produção, o custo explode silenciosamente: prompts repetidos, chamadas redundantes e modelo caro onde um barato bastaria. Reduzir custo não é "usar menos IA": é **usar a infraestrutura certa**: cache, batch e *model routing*.

ANALOGIA DO BUFFET

Token é a comida no prato: você paga por grama. **Cache semântico** é guardar a sobra na geladeira: se outro pede a mesma coisa, você serve do pote, não cozinha de novo. **Batch** é fazer 100 pratos de uma vez no forno, mais barato que um a um. **Model routing** é mandar o prato simples pro cozinheiro júnior e o complexo pro chef: paga o chef só quando precisa.

2. Diagnóstico

Toda pergunta ia direto pro modelo flagship, sem reaproveitar respostas idênticas e sem agrupar chamadas. A fatura crescia 20% ao mês e ninguém sabia qual fluxo consumia mais. O custo era **opaco e não-atribuído**.




Raiz do problema: 100% das chamadas no modelo caro, sem cache de respostas repetidas e sem roteamento por complexidade. Custo é arquitetura, não acidente.

3. Solução

Trinca de eficiência: (1) **cache semântico**: responde do cache quando a pergunta é similar a uma já respondida; (2) **batch**: empacota chamadas não-urgentes em lotes com desconto; (3) **model routing**: classifica a pergunta e manda pro modelo barato (ex.: mini) ou caro (frontier) conforme a complexidade.

4. Como funciona (pipeline)






5. Antes vs Depois

CENÁRIO	ANTES (FLAGSHIP PURO)	DEPOIS (ROUTING+CACHE+BATCH)
Resposta repetida	Recalculada	Servida do cache
Chamada simples	Modelo caro	Modelo barato
Lote	1 a 1	Batch com desconto
Visibilidade	Nenhuma	Custo por fluxo

6. Entregas

- **Módulo** model_router.py: classificação de complexidade e roteamento.
- **Cache** semantic_cache.py: cache de respostas por similaridade.
- **Script** batch_runner.py: empacotamento de chamadas assíncronas.

7. Métricas



Meta: reduzir o custo mensal em $\geq 85\%$ mantendo qualidade (score ≥ 0.90) via cache + routing + batch.

8. Status final

NÃO PUBLICADO : Desenvolvido e em homologação. Aguarda revisão antes de produção.